


# Uniwersytet Bielsko-Bialski

Wydział Budowy Maszyn i Informatyki

## Nauka o danych I

**Ćwiczenie numer:**

**2**

**Temat ćwiczenia:**

***Podstawowe operacje arytmetyczne w analizie danych***

Radosław Walczak

Nr albumu: 60038

# 1. Wstęp

Celem ćwiczenia było poznanie podstawowych operacji arytmetycznych i funkcji statystycznych stosowanych w analizie danych: średniej arytmetycznej, mediany, odchylenia standardowego, wariancji, korelacji i kowariancji oraz ich obliczenie w Pythonie z użyciem bibliotek numpy i pandas.

Operacje wykonano na dwóch zbiorach. Część A: zbiór „XAUUSD Gold Price Historical Data 2004-2024" z Kaggle, plik XAU_15m_data.csv z 15-minutowymi notowaniami ceny złota. Zbiór ma 494 235 wierszy i kolumny Date, Open, High, Low, Close, Volume. Część B: zbiór GBD 2019, Smoking Tobacco Use Prevalence 1990-2019 z ćwiczenia 1. Zbiór ma 20 970 wierszy i kolumny location, sex, year, val, upper, lower.

Dane A: https://www.kaggle.com/datasets/novandraanugrah/xauusd-gold-price-historical-data-2004-2024

Dane B: https://ghdx.healthdata.org/record/ihme-data/gbd-2019-smoking-tobacco-use-prevalence-1990-2019

Zadanie wykonano w notatniku Jupyter, w języku Python 3. Notatnik lab2_podstawowe_operacje.ipynb umieszczono w repozytorium:

**https://github.com/RadoslawWalczak63/nod_lab2**

# 2. Przebieg ćwiczenia

## 2.1. Część A: ceny złota XAU/USD

### Krok 1. Import bibliotek

Zaimportowano biblioteki `numpy` do obliczeń, `pandas` do ramek danych oraz `kagglehub` do pobrania zbioru z Kaggle.

```
import numpy as np
import pandas as pd
import kagglehub
from kagglehub import KaggleDatasetAdapter
```

### Krok 2. Wczytanie danych

Plik `XAU_15m_data.csv` pobrano funkcją `dataset_load()`, plik używa separatora średnik.

```
plik = "XAU_15m_data.csv"
df = kagglehub.dataset_load(
    KaggleDatasetAdapter.PANDAS,
    "novandraanugrah/xauusd-gold-price-historical-data-2004-2024",
    plik,
    pandas_kwargs={"delimiter": ";"},
)
df.head()
```

*Wynik w konsoli:*

```
               Date   Open   High    Low  Close  Volume
0  2004.06.11 07:15  384.0  384.3  383.8  384.3      12
1  2004.06.11 07:30  383.8  384.3  383.6  383.8      12
2  2004.06.11 07:45  383.3  383.8  383.3  383.8      20
3  2004.06.11 08:00  383.8  384.1  383.6  383.6       8
4  2004.06.11 08:15  383.6  384.3  383.5  383.5      20
```

Wynik: 494 235 świec 15-minutowych z kolumnami Date, Open, High, Low, Close, Volume.

### Krok 3. Podstawowe informacje o zbiorze

Sprawdzono rozmiar zbioru, brakujące wartości oraz statystyki opisowe `describe()`.

```
display(df.shape)
display(df.isna().sum())
df.describe()
```

*Wynik w konsoli:*

```
(494235, 6)
Date      0
Open      0
High      0
Low       0
Close     0
Volume    0
dtype: int64
                Open           High            Low          Close  \
count  494235.000000  494235.000000  494235.000000  494235.000000
mean     1425.545439    1426.506119    1424.559039    1425.548296
std       671.753822     672.309267     671.167825     671.764196
min       381.300000     381.600000     381.100000     381.300000
25%      1086.765000    1087.550000    1085.950000    1086.760000
50%      1305.940000    1306.630000    1305.230000    1305.940000
75%      1757.320000    1758.510000    1756.110000    1757.350000
max      5585.790000    5597.600000    5577.410000    5585.900000

              Volume
count  494235.000000
mean      988.000212
std      1758.706488
min         1.000000
25%       196.000000
50%       629.000000
75%      1195.000000
max    129960.000000
```

Wynik: zbiór ma 494 235 wierszy i 6 kolumn, nie zawiera braków.

### Krok 4. Średnia arytmetyczna

Średnia to suma wartości podzielona przez ich liczbę: $\bar{x} = (1/n) \cdot \Sigma x_i$. Wyliczono maksimum, minimum i średnią ceny `High`.

```
print("Maksimum:", np.max(df["High"]))
print("Minimum: ", np.min(df["High"]))
print("Średnia: ", np.mean(df["High"]))
```

*Wynik w konsoli:*

```
Maksimum: 5597.6
Minimum:  381.6
Średnia:  1426.5061187896447
```

Wynik: cena High mieści się w przedziale 381,6 do 5597,6, średnia wynosi ok. 1426,51.

### Krok 5. Mediana

Mediana to wartość środkowa uporządkowanego zbioru , dla parzystego n to średnia dwóch środkowych. Wynik funkcji `np.median()` porównano z obliczeniem ze wzoru.

```
n = len(df["High"])
print("Liczba obserwacji:", n)
print("Mediana numpy:  ", np.median(df["High"]))

posortowane = np.sort(df["High"].to_numpy())
mediana = posortowane[n // 2] if n % 2 else (posortowane[n // 2 - 1] + posortowane[n //
2]) / 2
print("Mediana ze wzoru:", mediana)
```

*Wynik w konsoli:*

```
Liczba obserwacji: 494235
Mediana numpy:   1306.63
Mediana ze wzoru: 1306.63
```

Wynik: mediana 1306,63, obie metody zgodne, niższa od średniej, rozkład jest prawostronnie asymetryczny.

### Krok 6. Odchylenie standardowe

Miara rozproszenia względem średniej: $\sigma = \sqrt{(1/n) \cdot \Sigma (x_i - \bar{x})^2}$.

```
print("Odchylenie standardowe numpy:   ", np.std(df["High"]))
print("Odchylenie standardowe ze wzoru:", np.sqrt(np.mean((df["High"] -
df["High"].mean()) ** 2)))
```

*Wynik w konsoli:*

```
Odchylenie standardowe numpy:    672.3085871081163
Odchylenie standardowe ze wzoru: 672.3085871081163
```

Wynik: $\sigma \approx 672{,}31$, wynik ze wzoru identyczny z np.std().

### Krok 7. Wariancja

Wariancja to kwadrat odchylenia standardowego: $Var(X) = (1/n) \cdot \Sigma (x_i - \bar{x})^2$.

```
wariancja = np.var(df["High"])
print("Wariancja numpy:   ", wariancja)
print("Wariancja ze wzoru:", np.mean((df["High"] - df["High"].mean()) ** 2))
print("Odchylenie^2:        ", np.std(df["High"]) ** 2)
```

*Wynik w konsoli:*

```
Wariancja numpy:    451998.8362993116
Wariancja ze wzoru: 451998.8362993116
Odchylenie^2:         451998.8362993116
```

Wynik: wariancja ≈ 451 998,84 i jest równa kwadratowi odchylenia standardowego.

**Krok 8. Korelacja**

Korelacja Pearsona mierzy liniową zależność dwóch zmiennych: ρ = Cov(X, Y) / (σX · σY). Zbadano zależność między cenami `High` i `Low`.

```
np.corrcoef(df["High"], df["Low"])[0, 1]
```

*Wynik w konsoli:*

```
np.float64(0.9999952138297385)
```

Wynik: ρ ≈ 0,999995: praktycznie idealna dodatnia zależność liniowa.

**Krok 9. Kowariancja**

Kowariancja mierzy współzależność dwóch zmiennych: Cov(X, Y) = (1/n) · Σ $(x_i - \bar{x})(y_i - \bar{y})$. Funkcja `np.cov()` dzieli przez n − 1 i zwraca macierz kowariancji.

```
kowariancja = np.cov(df["High"], df["Low"])
kowariancja
```

*Wynik w konsoli:*

```
array([[451999.75084351, 451230.18899553],
       [451230.18899553, 450466.24938756]])
```

Wynik: macierz 2 × 2, kowariancja High-Low ≈ 451 230,19.

**Krok 10. Korelacja z kowariancji**

Sprawdzono wzór ρ = Cov / (σX · σY) na macierzy kowariancji i porównano z `np.corrcoef()`.

```
korelacja = kowariancja[0, 1] / (np.sqrt(kowariancja[0, 0]) * np.sqrt(kowariancja[1, 1]))
print("Ze wzoru:     ", korelacja)
print("np.corrcoef:  ", np.corrcoef(df["High"], df["Low"])[0, 1])
print("Zgodność:     ", np.isclose(korelacja, np.corrcoef(df["High"], df["Low"])[0, 1]))
```

*Wynik w konsoli:*

```
Ze wzoru:      0.9999952138297385
np.corrcoef:   0.9999952138297385
Zgodność:      True
```

Wynik: obie metody dają ten sam wynik.

**Krok 11. Przykład z instrukcji: małe dane**

Dla danych `[1..5]` i `[5..1]` obliczono wszystkie miary. Pokazuje to różnicę między kowariancją z dzieleniem przez n − 1, domyślnie w numpy, i przez n, czyli wzorem z instrukcji i `bias=True`.

```
data1 = [1, 2, 3, 4, 5]
data2 = [5, 4, 3, 2, 1]
print("Średnia:     ", np.mean(data1))
print("Mediana:     ", np.median(data1))
print("Odch. std.:  ", np.std(data1))
print("Wariancja:   ", np.var(data1))
print("Korelacja:   ", np.corrcoef(data1, data2)[0, 1])
print("Kowariancja n-1:", np.cov(data1, data2)[0, 1])
print("Kowariancja n:  ", np.cov(data1, data2, bias=True)[0, 1])
```

*Wynik w konsoli:*

```
Średnia:      3.0
Mediana:      3.0
Odch. std.:   1.4142135623730951
Wariancja:    2.0
Korelacja:    -0.9999999999999999
Kowariancja n-1: -2.5
Kowariancja n:   -2.0
```

Wynik: korelacja −1, kowariancja −2,5 (n − 1) lub −2,0 (n).

**Krok 12. Przykład praktyczny: dwa sklepy**

Na przykładowych danych o cenach i sprzedaży w dwóch sklepach policzono średnią, medianę, odchylenie standardowe i korelacje. W sklepie B występuje wartość odstająca.

```
sklepy = pd.DataFrame({
    "cena_A":      [10.0, 10.5, 11.0, 11.5, 12.0, 12.5, 13.0, 13.5, 14.0, 14.5, 15.0,
15.5],
    "sprzedaz_A":  [200, 195, 185, 180, 170, 165, 150, 148, 140, 130, 125, 120],
    "cena_B":      [9.0, 9.5, 10.0, 10.5, 11.0, 11.5, 12.0, 12.5, 13.0, 13.5, 14.0,
14.5],
    "sprzedaz_B":  [220, 210, 205, 190, 185, 175, 170, 160, 150, 145, 135, 600],
})

wyniki = pd.DataFrame({
    "średnia":  [np.mean(sklepy[c]) for c in ["sprzedaz_A", "sprzedaz_B"]],
    "mediana":  [np.median(sklepy[c]) for c in ["sprzedaz_A", "sprzedaz_B"]],
    "odch_std": [np.std(sklepy[c]) for c in ["sprzedaz_A", "sprzedaz_B"]],
}, index=["Sklep A", "Sklep B"])
display(wyniki)

print("Korelacja cena-sprzedaż, sklep A:", np.corrcoef(sklepy["cena_A"],
sklepy["sprzedaz_A"])[0, 1])
print("Korelacja cena-sprzedaż, sklep B:", np.corrcoef(sklepy["cena_B"],
sklepy["sprzedaz_B"])[0, 1])
print("Korelacja sprzedaży A i B:       ", np.corrcoef(sklepy["sprzedaz_A"],
sklepy["sprzedaz_B"])[0, 1])
```

*Wynik w konsoli:*

```
            średnia  mediana    odch_std
Sklep A  159.000000    157.5   26.350206
Sklep B  212.083333    180.0  119.712474
Korelacja cena-sprzedaż, sklep A: -0.9967500038037731
Korelacja cena-sprzedaż, sklep B: 0.28281655167904185
Korelacja sprzedaży A i B:        -0.24700568659035085
```

Wynik: w sklepie B średnia (212) i odchylenie (120) są mocno zawyżone przez outlier, mediana (180) mniej, korelacja cena-sprzedaż to −0,997 w sklepie A i tylko 0,28 w sklepie B.

## 2.2. Część B: częstość palenia tytoniu, dane z lab1

### Krok 1. Wczytanie danych z lab1

Wczytano plik CSV z ćwiczenia 1 funkcją `read_csv()` i zostawiono kolumny `location`, `sex`, `year`, `val`, `upper`, `lower`.

```
from pathlib import Path

nazwa = "IHME_GBD_2019_SMOKING_TOB_1990_2019_PREV_Y2021M05D27.CSV"
plik = next(p for p in (Path(nazwa), Path("..") / "lab1" / nazwa) if p.exists())

df = pd.read_csv(plik).rename(columns={
    "location_name": "location", "sex_name": "sex", "year_id": "year",
})[["location", "sex", "year", "val", "upper", "lower"]]
display(df.shape)
display(df.isna().sum())
df.head()
```

*Wynik w konsoli:*

```
(20970, 6)
location    0
sex         0
year        0
val         0
upper       0
lower       0
dtype: int64
  location     sex  year       val     upper     lower
0   Global    Male  1990  0.450607  0.453930  0.446915
1   Global  Female  1990  0.106411  0.108623  0.104415
2   Global    Both  1990  0.278179  0.280235  0.276236
3   Global    Male  1991  0.447212  0.450214  0.443670
4   Global  Female  1991  0.105164  0.107276  0.103293
```

Wynik: 20 970 wierszy, 6 kolumn, brak brakujących wartości.

### Krok 2. Średnia, minimum i maksimum

Policzono średnią, minimum i maksimum kolumny `val`, czyli częstości palenia, oraz średnią osobno dla płci, bez rekordów `Both`.

```
print("Maksimum:", np.max(df["val"]))
print("Minimum: ", np.min(df["val"]))
print("Średnia: ", np.mean(df["val"]))
print()
plcie = df[df["sex"] != "Both"]
for p, g in plcie.groupby("sex"):
    print(f"Średnia {p}:", np.mean(g["val"]))
```

*Wynik w konsoli:*

```
Maksimum: 0.656046804
Minimum:  0.006671118
Średnia:  0.2205751410672866


Średnia Female: 0.11919753006895564
Średnia Male: 0.3224456251955651
```

Wynik: średnia częstość palenia ok. 22%, mężczyźni 32,2%, kobiety 11,9%.

**Krok 3. Mediana**

Medianę z `np.median()` porównano z obliczeniem ze wzoru i ze średnią.

```
x = np.sort(df["val"].to_numpy())
n = len(x)
mediana = x[n // 2] if n % 2 else (x[n // 2 - 1] + x[n // 2]) / 2
print("Liczba obserwacji:", n)
print("Mediana numpy: ", np.median(df["val"]))
print("Mediana wzór:  ", mediana)
print("Średnia:         ", np.mean(df["val"]))
```

*Wynik w konsoli:*

```
Liczba obserwacji: 20970
Mediana numpy:  0.214082475
Mediana wzór:   0.214082475
Średnia:          0.2205751410672866
```

Wynik: mediana 0,214, obie metody zgodne, bliska średniej 0,221, rozkład prawie symetryczny.

**Krok 4. Odchylenie standardowe i wariancja**

Obliczono σ i wariancję funkcjami numpy oraz ze wzoru.

```
sr = df["val"].mean()
print("Odchylenie standardowe numpy:", np.std(df["val"]))
print("Odchylenie standardowe wzór: ", np.sqrt(np.mean((df["val"] - sr) ** 2)))
print("Wariancja numpy:             ", np.var(df["val"]))
print("Odchylenie^2:                  ", np.std(df["val"]) ** 2)
```

*Wynik w konsoli:*

```
Odchylenie standardowe numpy: 0.13852964040595173
Odchylenie standardowe wzór:  0.13852964040595173
Wariancja numpy:              0.019190461271002292
Odchylenie^2:                   0.019190461271002292
```

Wynik: σ ≈ 0,1385, wariancja ≈ 0,0192 = $\sigma^2$.

**Krok 5. Porównanie miar dla mężczyzn i kobiet**

Wszystkie miary zebrano w jednej tabeli funkcjami `groupby` i `agg`.

```
tabela = plcie.groupby("sex")["val"].agg(
    srednia=np.mean, mediana=np.median, odch_std=np.std, wariancja=np.var
)
tabela
```

*Wynik w konsoli:*

```
         srednia   mediana  odch_std  wariancja
sex
Female  0.119198  0.071666  0.103097   0.010629
Male    0.322446  0.321532  0.129380   0.016739
```

Wynik: u kobiet mediana 7,2% jest dużo niższa od średniej 11,9%, u mężczyzn obie są zbliżone.

**Krok 6. Korelacja**

Zbadano korelację `val` z granicami przedziału niepewności oraz częstości palenia mężczyzn i kobiet w tym samym kraju i roku.

```
print("val vs lower:", np.corrcoef(df["val"], df["lower"])[0, 1])
print("val vs upper:", np.corrcoef(df["val"], df["upper"])[0, 1])

pivot = plcie.pivot_table(index=["location", "year"], columns="sex", values="val")
print("Mężczyźni vs kobiety:", np.corrcoef(pivot["Male"], pivot["Female"])[0, 1])
```

*Wynik w konsoli:*

```
val vs lower: 0.9986216186697856
val vs upper: 0.9985559263489542
Mężczyźni vs kobiety: 0.4231894318322434
```

Wynik: val-lower i val-upper ≈ 0,999, mężczyźni-kobiety ≈ 0,42, czyli umiarkowana.

**Krok 7. Kowariancja**

Policzono macierz kowariancji mężczyzn i kobiet, porównano dzielenie przez n − 1 i przez n.

```
kowariancja = np.cov(pivot["Male"], pivot["Female"])
display(kowariancja)
print("Cov n-1:", kowariancja[0, 1])
print("Cov n:  ", np.cov(pivot["Male"], pivot["Female"], bias=True)[0, 1])
```

*Wynik w konsoli:*

```
array([[0.01687647, 0.00568168],
       [0.00568168, 0.01068075]])
Cov n-1: 0.005681675716659971
Cov n:   0.005680855850034191
```

Wynik: Cov ≈ 0,005682 przy n − 1 i 0,005681 przy n, przy tylu obserwacjach różnica jest pomijalna.

**Krok 8. Korelacja z kowariancji**

Sprawdzono wzór ρ = Cov / (σX · σY) na macierzy kowariancji.

```
korelacja = kowariancja[0, 1] / (np.sqrt(kowariancja[0, 0]) * np.sqrt(kowariancja[1, 1]))
print("Ze wzoru:   ", korelacja)
print("np.corrcoef:", np.corrcoef(pivot["Male"], pivot["Female"])[0, 1])
print("Zgodność:   ", np.isclose(korelacja, np.corrcoef(pivot["Male"],
pivot["Female"])[0, 1]))
```

*Wynik w konsoli:*

```
Ze wzoru:    0.42318943183224333
np.corrcoef: 0.4231894318322434
Zgodność:    True
```

Wynik: 0,4232: zgodne z np.corrcoef().

**Krok 9. Trend w czasie: Polska**

Policzono korelację i kowariancję roku z częstością palenia dla Polski.

```
pl = plcie[plcie["location"] == "Poland"]
for p, g in pl.groupby("sex"):
    print(f"{p}: korelacja rok-val = {np.corrcoef(g['year'], g['val'])[0, 1]:.4f}, "
          f"kowariancja = {np.cov(g['year'], g['val'])[0, 1]:.5f}")
```

*Wynik w konsoli:*

```
Female: korelacja rok-val = -0.9191, kowariancja = -0.12187
Male: korelacja rok-val = -0.9592, kowariancja = -0.59372
```

Wynik: korelacja −0,96 u mężczyzn i −0,92 u kobiet, palenie systematycznie spada.

**Krok 10. Wartości odstające**

Dla mężczyzn w 2019 r. porównano średnią i medianę z danymi bez górnych 5% krajów.

```
rok = plcie[(plcie["year"] == 2019) & (plcie["sex"] == "Male")]["val"]
print("2019, mężczyźni: średnia:", np.mean(rok), " mediana:", np.median(rok), " odch.
std.:", np.std(rok))
print("Maksimum:", rok.max(), "-", plcie.loc[rok.idxmax(), "location"])
bez = rok[rok < rok.quantile(0.95)]
print("Bez górnych 5% : średnia:", np.mean(bez), " mediana:", np.median(bez))
```

*Wynik w konsoli:*

```
2019, mężczyźni: średnia: 0.2928170515021459  mediana: 0.274798432  odch. std.: 0.12448175125904722
Maksimum: 0.646348913 - Timor-Leste
Bez górnych 5% : średnia: 0.27865184157466066  mediana: 0.264071533
```

Wynik: średnia spada z 29,3% do 27,9%, mediana tylko z 27,5% do 26,4%, maksimum ma Timor-Leste, 64,6%.

## 3. Wnioski

Podczas ćwiczenia poznano podstawowe miary statystyczne i sposób ich obliczania w Pythonie:

• Średnia i mediana opisują typową wartość, dla ceny High złota średnia 1426,51 jest wyższa od mediany 1306,63, bo cena rosła przez 20 lat.

• Odchylenie standardowe i wariancja opisują zmienność, wariancja jest kwadratem odchylenia standardowego, co sprawdzono ze wzoru w obu zbiorach.

• Korelacja High-Low jest bliska 1, a korelacja liczona z kowariancji i odchyleń standardowych zgadza się z np.corrcoef().

• np.var() i np.std() dzielą domyślnie przez n, a np.cov() przez n − 1, przy porównaniach trzeba używać tego samego estymatora.

• Wartości odstające mocno zniekształcają średnią, odchylenie standardowe i korelację, np. w przykładzie ze sklepami, a mediana jest na nie odporna.

• W danych o paleniu mężczyźni palą ponad 2,5 raza częściej niż kobiety 32,2% wobec 11,9%, a w Polsce częstość palenia silnie maleje, korelacja z rokiem to −0,96 i −0,92.

• Częstość palenia mężczyzn i kobiet w tym samym kraju jest umiarkowanie skorelowana, $\rho \approx 0{,}42$.